

TD n°4 : Régression logistique en Python

L'objectif de ce TP est de mettre en pratique le langage Python pour réaliser une régression logistique. Il s'agit d'un algorithme de classification assez connu en apprentissage supervisé. Nous allons mettre en pratique cet algorithme, en utilisant Python et Scikit-Learn.

Jeu de données utilisé. Pour ce tutoriel, on utilisera le célèbre jeu de données Iris. Ce dernier est une base de données regroupant les caractéristiques de trois espèces de fleurs d'Iris, à savoir *Setosa*, *Versicolour* et *Virginica*. Chaque ligne de ce jeu de données est une observation des caractéristiques d'une fleur d'Iris. Ce dataset décrit les espèces d'Iris par quatre propriétés : longueur et largeur de sépales ainsi que longueur et largeur de pétales. La base de données comporte 150 observations (50 observations par espèce). Pour plus d'informations, Wikipedia https://fr.wikipedia.org/wiki/Iris_de_Fisher fournit des informations abondantes sur ce jeu de données.

Exercice 0: Implémentation de la régression logistique sur Iris.

1. Importez les bibliothèques `numpy`, `pyplot` (de `matplotlib`) et `sklearn` (qui est le nom de Scikit-Learn).
2. Chargez le package `datasets` de `sklearn` pour retrouver le jeu de données IRIS. Scikit-Learn vient avec un ensemble de jeu de données prêt à l'emploi pour des fins d'expérimentation. Ces dataset sont regroupés dans le package `sklearn.datasets`.
3. Chargez le jeu de données Iris, on utilise la méthode `load_iris()` du package `datasets`.
4. Affichez sur écran le jeu de données Iris.

Exercice 1: Adaptation de la base de données Iris. Comme on l'a évoqué précédemment, le dataset Iris se compose de quatre features (variables explicatives ou prédictives). Pour simplifier, on n'utilisera que les deux premières variables explicatives à savoir : `Sepal.length` et `Sepal.width`. De cette façon, on fera de la régression logistique dans un espace bidimensionnel.

Également, le jeu de données Iris se compose de trois classes, à savoir *Setosa*, *Versicolour* et *Virginica*. Les étiquettes y peuvent donc appartenir à l'ensemble $\{0, 1, 2\}$. Il s'agit donc d'une classification *Multi-classes*. La régression logistique étant un algorithme de classification *binnaire*, on va re-étiqueter les fleurs ayant le label (étiquette) 1 et 2 avec le label 1. Ainsi, on se retrouve avec un problème de classification binaire.

1. Prenez comme tableau x les deux premières colonnes du jeu de données Iris (utilisez la méthode `data`).
2. Prenez comme tableau y le target (cible) du jeu de données Iris, où vous re-étiquetez les fleurs ayant le label 1 et 2 avec le label 1 (utilisez la méthode `target`).

Exercice 2: Visualisation du jeu de données Utilisez `pyplot` pour visualiser les valeurs des deux variables explicatives du tableau x , en utilisant le vert pour les points avec l'étiquette 0 et le jaune pour les points avec l'étiquette 1.

On remarque que les données de la classe 0 et la classe 1 peuvent être *linéairement* séparées : une ligne droite peut séparer les points appartenant à la classe 0 et les points appartenant à la classe 1 dans le plan cartésien des deux variables explicatives.

Une régression logistique serait capable de départager les deux classes.

Exercice 3: Entraînement d'un modèle de régression logistique Scikit-Learn offre une classe d'implémentation de la régression logistique. Oninstanciera cette classe pour entraîner un modèle prédictif.

1. Importez la classe `LogisticRegression` de la bibliothèque `linear_model` de `sklearn`.
2. Créez un modèle pour la régression logistique, c'est-à-dire une objet de la classe `LogisticRegression`, avec le paramètre `C=1e20`.
3. Entraînez le modèle en utilisant la méthode `fit(x,y)` de la classe `LogisticRegression`, où la variable x est l'ensemble des observations qui serviront à l'entraînement de l'algorithme de Machine Learning (c'est-à-dire, les variables explicatives), et y est l'ensemble des étiquettes données aux observations.

Exercice 4: Prédire de la classe de nouvelles fleurs d'Iris Maintenant qu'on a entraîné notre algorithme de régression logistique, on va l'utiliser pour prédire la classe de fleurs d'Iris qui ne figuraient pas dans le jeu d'entraînement. Pour rappel, on a utilisé que les variables explicatives *Sepal Length* et *Sepal Width* pour entraîner notre jeu de données. Ainsi, nous allons fournir des valeurs pour ces deux variables et on demandera au modèle prédictif de nous indiquer la classe de la fleur.

1. Créez un tableau avec 4 nouvelles observations (c'est-à-dire, 4 nouvelles valeurs pour les variables explicatives).
2. Affichez les nouvelles observations en utilisant `pyplot`, avec une couleur différente de celles des données du jeu Iris.
3. Utilisez la méthode `predict()` de la classe `LogisticRegression` pour prédire à quelle classe les nouvelles observations appartiennent.
4. Vérifiez visuellement que l'étiquetage donné aux nouvelles observations et compatible avec les jeu de donnée Iris que vous avez visualisé dans l'exercice 2.

Par exemple, si votre tableau est

```
Iries_To_Predict = [  
    [5.5, 2.5],  
    [7, 3],  
    [3,2],  
    [5,3]  
]
```

alors la méthode `predict()` appliquée à `Iries_To_Predict` va dire que les deux premières observations appartiennent à la classe 1, et les deux dernières observations appartiennent à la classe 0.

Exercice 5: Régression logistique multi-classe. Telle qu'on l'a vu jusqu'ici, régression logistique permet uniquement de classifier binairement les observations (Spam/Non SPAM, MALIGNE/BENIGNE, NOIR/BLANC ...) ce qui est assez contraignant !

Le jeu de données Iris originaire classifie les fleurs d'iris en 3 classes. Comment on peut faire de la régression logistique sur un nombre de classes supérieur à 2 (*multi-classes*)? On itère la régression logistique binaire plusieurs fois. Le principe est simple : il consiste à découper le problème de classification multi-classes en une multitude de problèmes de classification binaire.

1. Répétez les exercices 1-4, mais cette fois en re-étiquetant les fleurs ayant le label (étiquette) 0 et 2 avec le label 0.
2. Répétez les exercices 1-4, mais cette fois en re-étiquetant les fleurs ayant le label (étiquette) 0 et 1 avec le label 1.

À quelle classe appartiennent les nouvelles observations de l'exercice 4?